

TARİFNAME

MAKROEKONOMİK GÖSTERGELER VE TEKNİK VERİLER İLE ZENGİNLEŞTİRİLMİŞ ÇOK KATMANLI LSTM TABANLI HİSSE SENEDİ FİYAT TAHMİN SİSTEMİ VE YÖNTEMİ

Teknik Alan

Bu buluş, yapay zeka ve derin öğrenme teknolojileri kullanılarak finansal piyasalarda hisse senedi fiyat tahmini yapan bir sistem (1) ve yöntem ile ilgilidir. Özellikle zaman serisi verileri üzerinde çalışan LSTM (Long Short-Term Memory – Uzun Kısa Süreli Bellek) tabanlı derin öğrenme modelleri, makroekonomik veri entegrasyonu ve bu modelin son kullanıcıya sunulduğu web tabanlı bir tahmin platformu ile ilgilidir. Buluş, finansal teknoloji (FinTech), yapay zeka destekli karar destek sistemleri ve bilgisayar destekli finansal analiz alanlarını kapsamaktadır.

Tekniğin Bilinen Durumu

Günümüzde finansal piyasalarda hisse senedi fiyat tahminleri için çeşitli yöntemler kullanılmaktadır. Geleneksel teknik analiz yöntemleri olan hareketli ortalamalar (SMA – Simple Moving Average, EMA – Exponential Moving Average), RSI (Relative Strength Index – Göreceli Güç Endeksi) ve MACD (Moving Average Convergence Divergence – Hareketli Ortalama Yakınsama İraksama) gibi göstergeler kullanılarak manuel veya kural tabanlı tahmin yapılmaktadır. Bu yöntemler, karmaşık piyasa dinamiklerini yakalayamamakta ve insan önyargılarına açık bulunmaktadır.

Basit RNN (Recurrent Neural Network – Tekrarlayan Sinir Ağı) modelleri, zaman serisi verileri üzerinde çalışan temel sinir ağı modelleridir. Ancak "vanishing gradient" (kaybolan gradyan) problemi nedeniyle uzun vadeli bağımlılıkları öğrenmekte yetersiz kalmaktadırlar. Bu durum, finansal zaman serisi tahminlerinde kayıp (loss) değerlerinin yüksek olmasına neden olmaktadır. Mevcut teknikte yer alan tek veri kaynaklı LSTM modelleri, yalnızca hisse senedinin kendi teknik verilerini, yani OHLCV (Open – Açılış, High – En Yüksek, Low – En Düşük, Close – Kapanış, Volume – Hacim) verilerini kullanarak tahmin yapmaktadır. Bu modeller, piyasayı etkileyen makroekonomik faktörleri göz ardı etmektedir.

Tekniğin bilinen durumunda yer alan KR20220167039A sayılı Güney Kore patent dokümanında (Baekseok Üniversitesi, 2022) derin öğrenme ve ekonomik göstergeler tabanlı bir hisse senedi fiyat tahmin sistemi tanımlanmaktadır. Söz konusu patent, hisse fiyatını etkileyen ekonomik göstergeleri öncü göstergeler olarak analiz etmekte ve sürekli yinelemeli öğrenme ile tahmin yapmaktadır. Ancak bu patent, genel ekonomik göstergeleri "öncü göstergeler" olarak

sınıflandırmakta olup spesifik makroekonomik göstergelerin doğrudan model girdisi olarak entegrasyonunu, sistematik deneysel yöntemle belirlenen optimum zaman penceresi ve LSTM mimarisi kombinasyonunu ve modelin web tabanlı bir platform üzerinden son kullanıcıya sunulmasını kapsamamaktadır.

Tekniğin bilinen durumunda yer alan US20220058483A1 sayılı Birleşik Devletler patent dokümanında (AllocateRite LLC, 2022) finansal risk yönetimi amacıyla paralel ve çok katmanlı LSTM sinir ağı mimarileri önerilmektedir. Söz konusu patent, risk yönetimi odaklı olup paralel LSTM mimarileri kullanmaktadır; hisse senedi fiyat tahmini odaklı seri (ardışık) çok katmanlı LSTM mimarisi, makroekonomik göstergelerin teknik hisse verilerine eşzamanlı entegrasyonu ve farklı veri aralıklarının sistematik olarak karşılaştırılması gibi unsurları içermemektedir.

Tekniğin bilinen durumunda yer alan KR20210069888A sayılı Güney Kore patent dokümanında (ETRI, 2021) makine öğrenmesi tabanlı hisse senedi fiyat yönü tahmin yöntemi ve cihazı tanımlanmaktadır. Söz konusu patent, sınıflandırma (classification) yaklaşımı ile yalnızca fiyatın artacağını veya azalacağını tahmin etmekte olup, regresyon (regression) yaklaşımı ile fiyatın tam sayısal değerini tahmin etmemekte, makroekonomik göstergeler ve teknik verilerin kombinasyonunu kullanmamaktadır.

Bu sebeple mevcut teknikte bulunan çalışmalar ve eksiklikler göz önünde bulundurulduğunda, makroekonomik göstergelerin teknik hisse verilerine entegre edildiği, sistematik deneysel yöntemle optimize edilmiş çok katmanlı LSTM tabanlı bir hisse senedi fiyat tahmin sistemine ve bu sistemin web tabanlı bir platform üzerinden son kullanıcıya sunulmasına ihtiyaç duyulduğu anlaşılmaktadır.

Buluşun Amacı

Bu buluşun amacı, makroekonomik göstergeler ve teknik hisse senedi verileri ile zenginleştirilmiş, çok katmanlı LSTM tabanlı bir hisse senedi fiyat tahmin sistemi (1) ve yöntemi geliştirmektir.

Bu buluşun bir diğer amacı, VIX (Volatilite Endeksi), DXY (Dolar Endeksi), US10Y (ABD 10 Yıllık Tahvil Getirisi), XAUUSD (Altın/Dolar), SPX (S&P 500), DJI (Dow Jones), IXIC (NASDAQ Composite) ve RUT (Russell 2000) gibi 8 farklı makroekonomik göstergenin hisse senedinin teknik verileri ile birlikte kullanılarak tahmin doğruluğunun artırılmasını sağlamaktır.

Bu buluşun bir başka amacı, sistematik deneysel çalışmalar sonucunda belirlenen optimum LSTM mimarisi, zaman penceresi kombinasyonu ve hiperparametre konfigürasyonu ile mevcut tekniğe kıyasla daha düşük kayıp değerleri elde etmektir.

Bu buluşun bir başka amacı, model sonuçlarının web tabanlı bir platform üzerinden son kullanıcıya sunulmasını sağlamaktır.

5 Şekillerin Açıklaması

Bu buluşun amacına ulaşmak için gerçekleştirilen "Makroekonomik Göstergeler ve Teknik Veriler ile Zenginleştirilmiş Çok Katmanlı LSTM Tabanlı Hisse Senedi Fiyat Tahmin Sistemi ve Yöntemi" ekli şekillerde gösterilmiş olup;

Şekil-1; Buluş konusu sistemin (1) genel mimarisinin şematik görünümüdür.

10 Şekil-2; Buluş konusu sistemde (1) veri akışının adım adım gösterildiği diyagramdır.

Şekil-3; Buluş konusu sistemde (1) yer alan LSTM derin öğrenme modelinin (40) katman mimarisinin detaylı görünümüdür.

Şekillerdeki Referansların Açıklaması

15 Şekillerde yer alan parçalar tek tek numaralandırılmış olup, bu numaraların karşılıkları aşağıda verilmiştir:

Referans No	Açıklama
1	Sistem (Makroekonomik Göstergeler ve Teknik Veriler ile Zenginleştirilmiş Çok Katmanlı LSTM Tabanlı Hisse Senedi Fiyat Tahmin Sistemi)
10	Veri toplama modülü
11	Teknik veri kaynağı bileşeni
12	Makroekonomik veri kaynağı bileşeni
20	Veri ön işleme modülü
21	Tarih bazlı eşleştirme bileşeni
22	Min-Max normalizasyon bileşeni
23	Zaman penceresi (sliding window) oluşturma bileşeni
24	Eğitim-test ayrımı bileşeni
30	Yahoo Finance API (veri kaynağı arayüzü)
40	LSTM derin öğrenme modeli
41	Birinci LSTM gizli katmanı (128 nöron)
42	İkinci LSTM gizli katmanı (64 nöron)
43	Dense çıkış katmanı
50	Ters normalizasyon modülü
60	Web tabanlı sunum platformu (hamdiai.com)

Buluşun Açıklaması

Makroekonomik göstergeler ve teknik hisse senedi verileri ile zenginleştirilmiş, çok katmanlı LSTM tabanlı bir hisse senedi fiyat tahmin sistemi (1) ve yöntemi geliştirmek amacıyla buluş konusu sistem (1) aşağıda detaylı olarak açıklanmaktadır.

Buluş konusu sistem (1), hisse senedi piyasasında gelecekteki fiyat hareketlerini tahmin etmek amacıyla geliştirilen, makroekonomik göstergeler ile zenginleştirilmiş çok katmanlı LSTM (Uzun Kısa Süreli Bellek) tabanlı bir yapay zeka sistemidir. Buluş konusu sistem (1); en az bir veri toplama modülü (10), en az bir veri ön işleme modülü (20), en az bir LSTM derin öğrenme modeli (40), en az bir ters normalizasyon modülü (50) ve en az bir web tabanlı sunum platformu (60) içermektedir.

Veri Toplama Modülü (10)

Buluş konusu sistemde (1) yer alan veri toplama modülü (10), Yahoo Finance API (30) aracılığıyla hedef hisse senetlerinin ve makroekonomik göstergelerin günlük verilerini toplamak üzere yapılandırılmaktadır.

Veri toplama modülü (10), en az bir teknik veri kaynağı bileşeni (11) ve en az bir makroekonomik veri kaynağı bileşeni (12) içermektedir.

Teknik veri kaynağı bileşeni (11), Yahoo Finance API (30) üzerinden hedef hisse senetlerinin (AAPL – Apple Inc., NVDA – NVIDIA Corporation, TSLA – Tesla Inc. ve benzeri hisse senetleri) günlük teknik verilerini toplamak üzere yapılandırılmaktadır. Teknik veri kaynağı bileşeni (11) tarafından toplanan veriler; açılış fiyatı (Open), kapanış fiyatı (Close), en yüksek fiyat (High), en düşük fiyat (Low) ve işlem hacmi (Volume) olmak üzere 5 farklı teknik göstergeden oluşmaktadır. Bu veriler, OHLCV (Open, High, Low, Close, Volume) formatında günlük bazda temin edilmektedir.

Makroekonomik veri kaynağı bileşeni (12), Yahoo Finance API (30) üzerinden 8 farklı makroekonomik göstergenin günlük verilerini toplamak üzere yapılandırılmaktadır. Makroekonomik veri kaynağı bileşeni (12) tarafından toplanan göstergeler şunlardır:

- VIX (CBOE Volatility Index – Volatilite Endeksi): Piyasa volatilitelerini ölçen ve yatırımcı korku seviyesini yansıtan bir endekstir.
- DXY (US Dollar Index – ABD Dolar Endeksi): ABD dolarının altı büyük para birimi karşısındaki değerini ölçen bir endekstir.
- US10Y (US 10-Year Treasury Yield – ABD 10 Yıllık Tahvil Getirisi): ABD devlet tahvillerinin 10 yıllık getiri oranını gösteren bir göstergedir.

- XAUUSD (Gold/US Dollar – Altın/ABD Doları): Altın fiyatının ABD doları cinsinden değerini gösteren bir göstergedir.
- SPX (S&P 500 Index): ABD borsasında işlem gören en büyük 500 şirketi temsil eden bir piyasa endeksidir.
- DJI (Dow Jones Industrial Average – Dow Jones Sanayi Ortalaması): ABD'nin en büyük 30 sanayi şirketini temsil eden bir piyasa endeksidir.
- IXIC (NASDAQ Composite Index – NASDAQ Bileşik Endeksi): NASDAQ borsasında işlem gören tüm hisse senetlerini kapsayan bir piyasa endeksidir.
- RUT (Russell 2000 Index): ABD borsasında işlem gören küçük ölçekli 2000 şirketi temsil eden bir piyasa endeksidir.

Veri toplama modülü (10), veri aralığı olarak 2020/01/01 tarihinden güncel tarihe kadar olan verileri toplamak üzere yapılandırılmaktadır. Bu veri aralığı, deneysel çalışmalar sonucunda 2000-2025, 2010-2025 ve 2020-2025 aralıkları sistematik olarak karşılaştırılarak optimum eğitim verisi aralığı olarak belirlenmiştir. 2020-2025 veri aralığının tercih edilmesinin sebebi, daha güncel piyasa dinamiklerini yansıtmaması ve modelin güncel koşullara daha iyi uyum sağlamasıdır.

Veri Ön İşleme Modülü (20)

Buluş konusu sistemde (1) yer alan veri ön işleme modülü (20), veri toplama modülünden (10) gelen ham verileri LSTM derin öğrenme modeline (40) uygun formata dönüştürmek üzere yapılandırılmaktadır.

Veri ön işleme modülü (20); en az bir tarih bazlı eşleştirme bileşeni (21), en az bir Min-Max normalizasyon bileşeni (22), en az bir zaman penceresi oluşturma bileşeni (23) ve en az bir eğitim-test ayrımı bileşeni (24) içermektedir.

Tarih bazlı eşleştirme bileşeni (21), teknik veri kaynağı bileşeninden (11) gelen hisse senedi OHLCV verilerini ve makroekonomik veri kaynağı bileşeninden (12) gelen 8 makroekonomik gösterge verisini tarih bazında eşleştirmek ve tek bir veri çerçevesinde (dataframe) birleştirmek üzere yapılandırılmaktadır. Bu birleştirme işlemi sonucunda her bir tarih satırı, 5 teknik gösterge ve 8 makroekonomik gösterge olmak üzere toplam 13 özellik (feature) içeren bir veri seti oluşturulmaktadır.

Min-Max normalizasyon bileşeni (22), birleştirilmiş veri setindeki tüm değerleri 0 ile 1 aralığına dönüştürmek üzere yapılandırılmaktadır. Min-Max normalizasyonu, her bir özellik sütunu için aşağıdaki formül kullanılarak uygulanmaktadır:

$$X_{norm} = (X - X_{min}) / (X_{max} - X_{min})$$

Bu normalizasyon işlemi, farklı ölçeklerdeki verilerin (örneğin, hisse senedi fiyatı ile işlem hacmi gibi büyüklük farkı olan değerlerin) LSTM derin öğrenme modeli (40) tarafından eşit ağırlıkta değerlendirilmesini sağlamak amacıyla gerçekleştirilmektedir.

- 5 Zaman penceresi oluşturma bileşeni (23), normalize edilmiş veri seti üzerinde kayar zaman penceresi (sliding window) yöntemi ile LSTM derin öğrenme modeline (40) uygun girdi-çıkı çiftleri oluşturmak üzere yapılandırılmaktadır. Her bir zaman penceresi, son 30 günlük geçmiş veriyi girdi (input) olarak almakta ve 10 gün sonraki kapanış fiyatını hedef değer (target) olarak içermektedir. Bu zaman penceresi kombinasyonu (30 gün geriye bakış, 10 gün ileri tahmin),
- 10 sistematik deneysel çalışmalar sonucunda farklı kombinasyonlar (7/1, 14/1, 30/1, 30/5, 30/10, 60/10 gibi) karşılaştırılarak optimum kombinasyon olarak belirlenmiştir. Böylece LSTM derin öğrenme modelinin (40) girdi verisi, her bir örnek (sample) için (30, 13) boyutunda bir üç boyutlu tensör yapısında düzenlenmektedir; burada 30 zaman adımını ve 13 özellik sayısını temsil etmektedir.
- 15 Eğitim-test ayrımı bileşeni (24), oluşturulan zaman penceresi veri setini %80 eğitim (training) ve %20 test (testing) olarak ayırmak üzere yapılandırılmaktadır. Bu ayrım, kronolojik sıra korunarak (zaman serisi veri sızıntısını önlemek amacıyla) gerçekleştirilmektedir.

LSTM Derin Öğrenme Modeli (40)

- 20 Buluş konusu sistemde (1) yer alan LSTM derin öğrenme modeli (40), veri ön işleme modülünden (20) gelen eğitim verilerini kullanarak hisse senedi fiyat tahmini yapmak üzere eğitilen çok katmanlı bir derin öğrenme modeli olarak yapılandırılmaktadır. LSTM derin öğrenme modeli (40); en az bir birinci LSTM gizli katmanı (41), en az bir ikinci LSTM gizli katmanı (42) ve en az bir Dense çıkış katmanı (43) içermektedir.
- 25 LSTM (Long Short-Term Memory – Uzun Kısa Süreli Bellek) mimarisi, standart RNN (Recurrent Neural Network – Tekrarlayan Sinir Ağı) modellerindeki "vanishing gradient" (kaybolan gradyan) problemini çözmek amacıyla geliştirilmiş özel bir tekrarlayan sinir ağı türüdür. LSTM mimarisi, her bir zaman adımında üç adet kapı (gate) mekanizması içermektedir: Unutma Kapısı (Forget Gate): Hücre durumundaki (cell state) hangi bilgilerin unutulması
- 30 gerektiğine karar veren mekanizmadır. Sigmoid aktivasyon fonksiyonu kullanılarak 0 ile 1 arasında bir değer üretir; burada 0 tamamen unutmayı ve 1 tamamen hatırlamayı ifade etmektedir.

$$f_t = \sigma(W_f \cdot [h_{(t-1)}, x_t] + b_f)$$

- Giriş Kapısı (Input Gate): Yeni gelen bilgilerden hangilerinin hücre durumuna eklenmesi
- 35 gerektiğine karar veren mekanizmadır.

$$i_t = \sigma(W_i \cdot [h_{(t-1)}, x_t] + b_i)$$

Çıkış Kapısı (Output Gate): Hücre durumundaki bilgilerden hangilerinin çıktı olarak verilmesi gerektiğine karar veren mekanizmadır.

$$o_t = \sigma(W_o \cdot [h_{(t-1)}, x_t] + b_o)$$

Bu kapı mekanizmaları sayesinde LSTM mimarisi, uzun vadeli bağımlılıkları öğrenme kapasitesine sahip olup, hücre durumu (cell state) aracılığıyla uzun süreli hafıza işlevi görmektedir. Bu özellik, finansal zaman serisi verilerinde geçmiş fiyat hareketlerinin ve makroekonomik trendlerin gelecekteki fiyatlar üzerindeki etkisini yakalamak açısından kritik öneme sahiptir.

Birinci LSTM gizli katmanı (41), 128 nöron içeren bir LSTM katmanı olarak yapılandırılmaktadır. Birinci LSTM gizli katmanı (41), return_sequences=True parametresi ile yapılandırılmış olup, her bir zaman adımı için 128 boyutlu bir çıktı vektörü üretmekte ve bu çıktıyı ikinci LSTM gizli katmanına (42) aktarmaktadır. Birinci LSTM gizli katmanının (41) çıktı şekli (batch_size, 30, 128) boyutunda bir tensördür; burada 30 zaman adımını ve 128 her bir zaman adımındaki çıktı boyutunu temsil etmektedir.

İkinci LSTM gizli katmanı (42), 64 nöron içeren bir LSTM katmanı olarak yapılandırılmaktadır. İkinci LSTM gizli katmanı (42), return_sequences=False parametresi ile yapılandırılmış olup, yalnızca son zaman adımının 64 boyutlu temsilini üretmektedir. Bu sayede birinci LSTM gizli katmanından (41) gelen sıralı bilgi, daha kompakt bir temsile dönüştürülmektedir. İkinci LSTM gizli katmanının (42) çıktı şekli (batch_size, 64) boyutundadır.

Dense çıkış katmanı (43), 1 nöron içeren tam bağlantılı (fully connected) bir katman olarak yapılandırılmaktadır. Dense çıkış katmanında (43) aktivasyon fonksiyonu kullanılmamakta olup, doğrusal (linear) çıktı sağlamaktadır. Bu yapılandırma, regresyon (regression) görevi için uygundur ve doğrudan sayısal fiyat tahmini çıktısı vermektedir. Dense çıkış katmanının (43) çıktı şekli (batch_size, 1) boyutundadır.

LSTM derin öğrenme modeli (40), dropout (seyreltme) kullanılmadan yapılandırılmaktadır. Deneyisel çalışmalar sonucunda modelin underfitting (yetersiz öğrenme) durumunda olduğu tespit edilmiş ve dropout uygulamasının öğrenmeyi daha da yavaşlattığı belirlenmiştir. Bu nedenle dropout oranı sıfır olarak belirlenmiştir.

LSTM derin öğrenme modeli (40), MSE (Mean Squared Error – Ortalama Karesel Hata) kayıp fonksiyonu ile derlenmektedir. MSE kayıp fonksiyonu aşağıdaki formül ile hesaplanmaktadır:

$$MSE = (1/n) \sum (y_i - \hat{y}_i)^2$$

Burada y_i gerçek değeri, $\hat{y}_i$ tahmin edilen değeri ve n örnek sayısını temsil etmektedir. Adam (Adaptive Moment Estimation) optimizör algoritması ile model ağırlıkları güncellenmektedir.

LSTM derin öğrenme modeli (40), 200 epoch (devir) boyunca eğitilmektedir. Epoch sayısı, deneysel çalışmalar sonucunda 50, 100, 150, 200 ve 300 epoch değerleri karşılaştırılarak optimum değer olarak belirlenmiştir.

- 5 128-64 nöron kombinasyonlu, 2 gizli katmanlı LSTM mimarisi, sistematik deneysel çalışmalar sonucunda farklı konfigürasyonlar (64 nöron/1 katman, 128 nöron/1 katman, 64-32 nöron/2 katman, 128-64 nöron/2 katman, 256-128-64 nöron/3 katman gibi) karşılaştırılarak optimum konfigürasyon olarak belirlenmiştir.

10 **Ters Normalizasyon Modülü (50)**

Buluş konusu sistemde (1) yer alan ters normalizasyon modülü (50), LSTM derin öğrenme modelinin (40) ürettiği 0 ile 1 arasındaki normalize çıktı değerlerini gerçek fiyat değerlerine geri dönüştürmek üzere yapılandırılmaktadır. Ters normalizasyon işlemi, Min-Max normalizasyon bileşeni (22) tarafından kaydedilen minimum ve maksimum değerler kullanılarak aşağıdaki formül ile gerçekleştirilmektedir:

$$X_{gerçek} = X_{norm} \times (X_{max} - X_{min}) + X_{min}$$

Ters normalizasyon modülü (50), 10 günlük tahmin değerlerini gerçek para birimi (ABD Doları) cinsinden fiyat değerlerine dönüştürerek son kullanıcının anlayabileceği formatta sunmaktadır.

20 **Buluşun Sanayiye Uygulanma Biçimi**

Web Tabanlı Sunum Platformu (60)

Buluş konusu sistemde (1) yer alan web tabanlı sunum platformu (60), hamdiai.com adresi üzerinden hizmet vermek üzere yapılandırılmaktadır. Web tabanlı sunum platformu (60), LSTM derin öğrenme modelinin (40) ürettiği ve ters normalizasyon modülü (50) tarafından gerçek fiyat değerlerine dönüştürülen tahmin sonuçlarını, kullanıcı dostu bir web arayüzü üzerinden son kullanıcılara sunmak üzere yapılandırılmaktadır.

Web tabanlı sunum platformu (60); tahmin grafiklerinin görüntülenmesini, gerçek fiyat değerleri ile tahmin edilen fiyat değerlerinin karşılaştırmalı olarak gösterilmesini ve kullanıcı etkileşimini sağlamak üzere yapılandırılmaktadır. Son kullanıcı, karmaşık veri setleri ve grafikler ile uğraşmaksızın, yapay zeka destekli tahmin sonuçlarına doğrudan internet üzerinden erişebilmektedir.

Buluş konusu sistemde (1) yer alan cihaz (2) ve sunucu (3) kullanıcıya veri gizliliği ilkeleri doğrultusunda bilgilendirme ve onay sunmakta olup, Kişisel Verilerin Korunması Kanunu (KVKK) dahilinde faaliyet göstermektedir.

Bu temel kavramlar etrafında, buluş konusu "Makroekonomik Göstergeler Ve Teknik Veriler İle Zenginleştirilmiş Çok Katmanlı Lstm Tabanlı Hisse Senedi Fiyat Tahmin Sistemi Ve Yöntemi (1)" ile ilgili çok çeşitli uygulamaların geliştirilmesi mümkün olup, buluş burada açıklanan 5 örneklerle sınırlandırılmaz, esas olarak istemlerde belirtildiği gibidir.

İSTEMLER

1. Makroekonomik göstergeler ve teknik veriler ile zenginleştirilmiş çok katmanlı LSTM tabanlı hisse senedi fiyat tahmin sistemi (1) olup özelliği; Yahoo Finance API (30) aracılığıyla hedef hisse senetlerinin OHLCV verilerini toplayan en az bir teknik veri kaynağı bileşeni (11) ve VIX, DXY, US10Y, XAUUSD, SPX, DJI, IXIC ve RUT makroekonomik göstergelerinin günlük verilerini toplayan en az bir makroekonomik veri kaynağı bileşeni (12) içeren en az bir veri toplama modülü (10); tarih bazlı eşleştirme bileşeni (21), Min-Max normalizasyon bileşeni (22), zaman penceresi oluşturma bileşeni (23) ve eğitim-test ayrımı bileşeni (24) içeren en az bir veri ön işleme modülü (20); 128 nöron içeren birinci LSTM gizli katmanı (41), 64 nöron içeren ikinci LSTM gizli katmanı (42) ve 1 nöron içeren Dense çıkış katmanı (43) içeren en az bir LSTM derin öğrenme modeli (40); en az bir ters normalizasyon modülü (50) ve en az bir web tabanlı sunum platformu (60) içermesidir.
2. İstem 1'e göre hisse senedi fiyat tahmin sistemi (1) olup özelliği; veri toplama modülünün (10), teknik veri kaynağı bileşeni (11) aracılığıyla hedef hisse senetlerinin açılış fiyatı (Open), kapanış fiyatı (Close), en yüksek fiyat (High), en düşük fiyat (Low) ve işlem hacmi (Volume) olmak üzere 5 farklı OHLCV verisini ve makroekonomik veri kaynağı bileşeni (12) aracılığıyla 8 farklı makroekonomik göstergenin günlük kapanış değerlerini 2020/01/01 tarihinden güncel tarihe kadar toplamak üzere yapılandırılmasıdır.
3. İstem 1 veya 2'ye göre hisse senedi fiyat tahmin sistemi (1) olup özelliği; veri ön işleme modülünün (20), tarih bazlı eşleştirme bileşeni (21) ile teknik ve makroekonomik verileri tarih bazında eşleştirerek toplam 13 özellik içeren bir veri seti oluşturma, Min-Max normalizasyon bileşeni (22) ile tüm değerleri 0 ile 1 aralığına dönüştürmesi, zaman penceresi oluşturma bileşeni (23) ile 30 günlük kayar zaman pencereleri oluşturarak her bir örneğin (30, 13) boyutunda girdi tensörü ve 10 gün sonraki kapanış fiyatını hedef değer olarak içermesi, eğitim-test ayrımı bileşeni (24) ile veri setini kronolojik sıra korunarak %80 eğitim ve %20 test olarak ayırmasıdır.
4. İstem 1, 2 veya 3'e göre hisse senedi fiyat tahmin sistemi (1) olup özelliği; LSTM derin öğrenme modelinin (40), birinci LSTM gizli katmanının (41) 128 nöron ile return_sequences=True parametresiyle her bir zaman adımı için çıktı üretmesi, ikinci LSTM gizli katmanının (42) 64 nöron ile return_sequences=False parametresiyle yalnızca son zaman adımının temsiliyi üretmesi, Dense çıkış katmanının (43) 1 nöron ile doğrusal çıktı sağlaması,

MSE kayıp fonksiyonu ve Adam optimizör algoritması kullanılarak 200 epoch boyunca eğitilmesi ve dropout kullanılmadan yapılandırılmasıdır.

- 5 5. Makroekonomik göstergeler ve teknik veriler ile zenginleştirilmiş çok katmanlı LSTM tabanlı hisse senedi fiyat tahmin yöntemi olup özelliği; veri toplama modülü (10) ile Yahoo Finance API (30) üzerinden hedef hisse senedinin OHLCV verilerinin ve VIX, DXY, US10Y, XAUUSD, SPX, DJI, IXIC, RUT makroekonomik göstergelerinin günlük verilerinin toplanması, veri ön işleme modülü (20) ile tarih bazlı eşleştirme, Min-Max normalizasyon, 30 günlük kayar zaman penceresi oluşturma ve %80-%20 eğitim-test ayrımı işlemlerinin gerçekleştirilmesi, LSTM derin öğrenme modeli (40) ile 128 nöronlu birinci LSTM gizli katmanı (41), 64 nöronlu ikinci LSTM gizli katmanı (42) ve 1 nöronlu Dense çıkış katmanından (43) oluşan çok katmanlı yapıda MSE kayıp fonksiyonu ve Adam optimizör kullanılarak 200 epoch boyunca eğitim yapılması, ters normalizasyon modülü (50) ile tahmin sonuçlarının gerçek fiyat değerlerine dönüştürülmesi ve
- 10
- 15 web tabanlı sunum platformu (60) üzerinden sonuçların kullanıcıya sunulması adımlarını içermesidir.

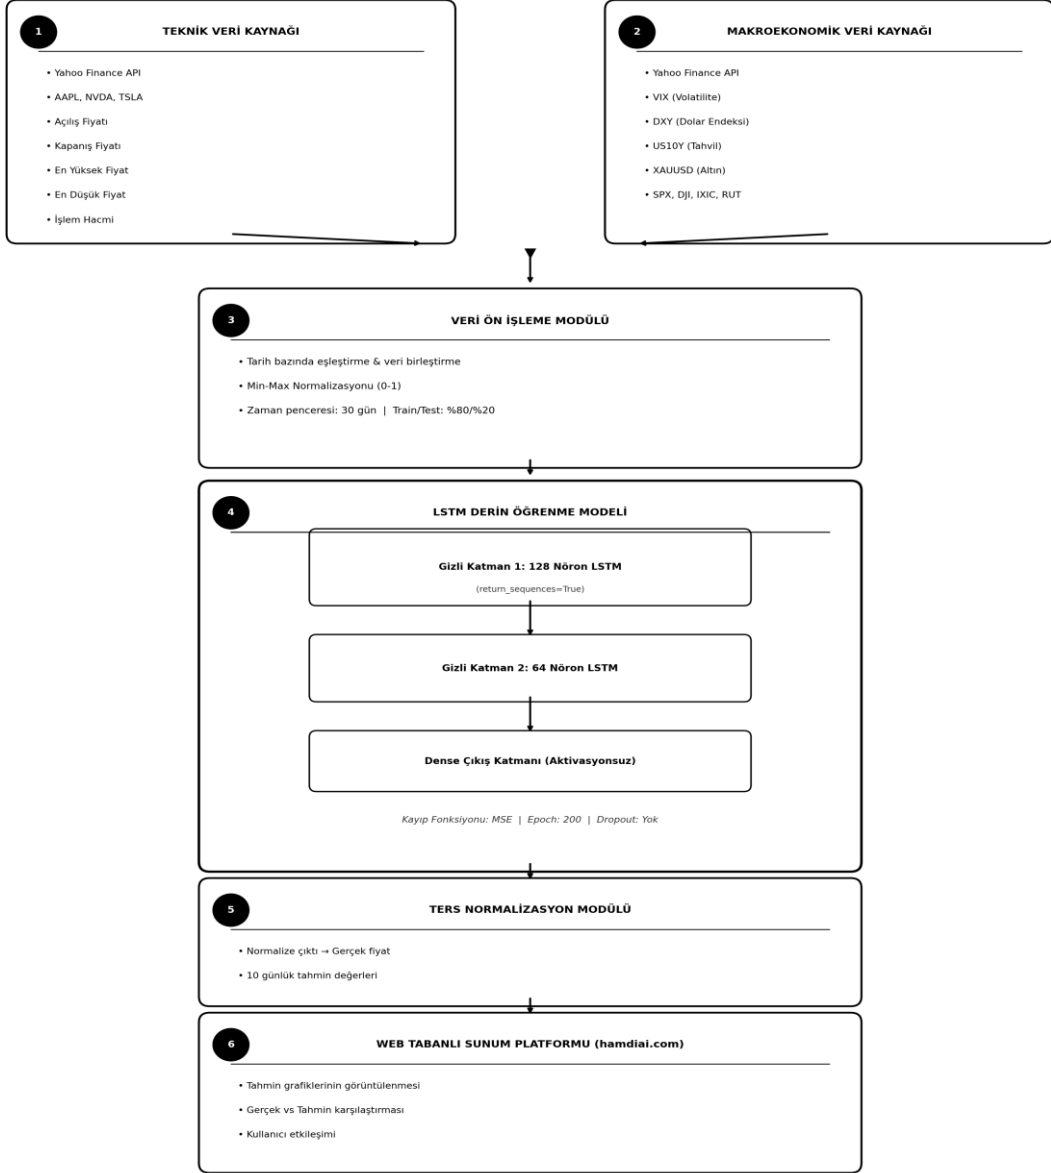
ÖZET

MAKROEKONOMİK GÖSTERGELER VE TEKNİK VERİLER İLE ZENGİNLEŞTİRİLMİŞ ÇOK KATMANLI LSTM TABANLI HİSSE SENEDİ FİYAT TAHMİN SİSTEMİ VE YÖNTEMİ

5


10 Bu buluş, yapay zeka ve derin öğrenme teknolojileri kullanılarak finansal piyasalarda hisse senedi fiyat tahmini yapan bir sistem (1) ve yöntem ile ilgilidir. Özellikle zaman serisi verileri üzerinde çalışan LSTM (Long Short-Term Memory – Uzun Kısa Süreli Bellek) tabanlı derin öğrenme modelleri, makroekonomik veri entegrasyonu ve bu modelin son kullanıcıya sunulduğu web tabanlı bir tahmin platformu ile ilgilidir. Buluş, finansal teknoloji (FinTech), yapay zeka destekli karar destek sistemleri ve bilgisayar destekli finansal analiz alanlarını kapsamaktadır.

Şekil 1: Sistem Mimarisi Genel Görünümü



Şekil 1


Şekil 2: Veri Akış Diyagramı



Şekil 2

Şekil 3: LSTM Model Mimarisi

(Çok Katmanlı Derin Öğrenme Modeli Detayı)



Şekil 3